

1. 实验目的

理解图像数据如何转换为机器学习模型可处理的特征向量。

掌握训练集与测试集的划分及其作用。

熟悉KNN、朴素贝叶斯、逻辑回归、SVM、决策树、随机森林等传统分类方法。

2. 数据集说明

数据集名称：sklearn 内置手写数字数据集 (load_digits)

图像大小：8 × 8 像素

样本数量：1797 张

类别数量：10 类 (数字 0~9)

特征向量表示：每张8×8的灰度图像 (像素值0~16) 按行展开成一个64维向量，作为模型的输入特征

部分样本图像及标签如下图所示

1.png

3. 实验方法

将1797张图像全部转换为64维向量，按 75% 训练、25% 测试 的比例随机划分 (random state=42)。
对于距离/内积敏感的模型 (SVM、逻辑回归)，先对特征进行标准化 (零均值单位方差)，再输入模型。所用五种以上方法如下：

方法 简要说明

KNN (k=5) 根据最近5个邻居样本的类别投票分类

Gaussian Naive Bayes 假设各像素独立，采用高斯分布估计概率

Logistic Regression 多分类softmax回归，学习线性分类边界

SVM (RBF核) 通过核函数寻找最大间隔非线性边界，参数 C=1, gamma='scale'

Decision Tree 根据特征阈值递归划分，基尼系数分裂

Random Forest (100棵树) 多棵决策树集成，投票决定最终类别

4. 实验结果

4.1 不同模型测试准确率

模型 测试准确率

KNN (k=5) 0.9822

Naive Bayes (Gaussian) 0.8578

Logistic Regression 0.9600

SVM (RBF, 标准化) 0.9911

Decision Tree 0.8400

Random Forest (100) 0.9778

准确率最高：SVM (0.9911)，其次为 KNN (0.9822)。

准确率最低：决策树 (0.8400)。


差异明显：最优与最差模型相差约15个百分点。

原因分析：

SVM 结合标准化与 RBF 核，能有效处理高维像素间的非线性关系，泛化能力强。KNN 基于像素距离直接度量，在小尺寸手写体上类内距离小。随机森林通过集成降低了单棵树的方差。朴素贝叶斯因假设像素独立且服从高斯分布，忽略了空间相关性，精度受限。决策树极易过拟合，对噪声和旋转敏感，泛化最弱。

4.2 混淆矩阵 (SVM)

SVM在测试集上的归一化混淆矩阵如下图所示：




主要混淆对：数字 8 易误判为 1、2、4、9；数字 5 与 8、9 混淆；4 与 9 互相误判。数字 0、3、6 几乎完全正确。

4.3 错误分类样本示例 (SVM)

以下为部分被SVM错分的样本（图像旁标注“真实→预测”）：

3.png



- 8→1：数字 8 上干部断开，形态接近倾斜的 1。
- 9→5：底部弯折过大，顶部未封闭，与 5 的特征相似。
- 4→9：竖笔缺失，像素图案呈圆形，接近 9。
- 2→8：下方横笔与弧线粘连，形成双圈结构，类似 8。

易混淆的根本原因： 8×8 极低分辨率下，部分数字的类间差异小于同一数字不同书写的类内差异；原始像素特征对位移、旋转、笔画粗细高度敏感，使得边缘样本落入错误区域。

5. 实验总结

基本流程：图像加载→向量展开→划分数据→（可选标准化）→训练传统模型→评估测试。
分类器比较：KNN简洁但预测慢；SVM核方法功能强大；随机森林平衡了偏差与方差；逻辑回归线性易解释；朴素贝叶斯简单但假设过强；单棵决策树易过拟合。